Fraud Detection System

Group C- Machine Learning

Project 2

12 January 2026

Team Member

ML - Bold

Bayu Abil Pratama

Dody Firmanda

Fahrul Rozi

Asriyadi

Background & Problem Statement

Fraud Kartu Kredit saat ini menyebabkan kerugian Senilai $10 Miliar pertahun.

Menurut Komisi Perdagangan Federal , Jaringan Pengawas Konsumen (Consumer Sentinel Network) menerima 2,6 juta laporan penipuan pada tahun 2023 saja — itu hampir $10 miliar kerugian akibat penipuan, meningkat 21 persen dari tahun sebelumnya. Angka tersebut akan terus meningkat seiring semakin banyak terutama konsumen menyukai belanja online.

Bagaimana cara mencegah Fraud kartu kredit?

Seiring dengan meningkatnya volume transaksi dan kompleksitas pola fraud, penggunaan metode berbasis machine learning dan data mining menjadi solusi yang efektif. Algoritma-algoritma ini dapat mempelajari pola historis transaksi dan mendeteksi anomali yang mengindikasikan adanya aktivitas fraud. Oleh karena itu, pengembangan sistem Credit Card Fraud Detection menjadi sangat penting untuk mendukung keamanan sistem keuangan modern.

Objectives & Scope

Objectives

- Untuk mengembangkan dan mengevaluasi model klasifikasi pembelajaran mesin yang dapat secara akurat memprediksi transaksi fraud.
- Mengimplementasikan dan melatih beberapa algoritma pembelajaran mesin (Logistik Regression, Random Forest, Adaboost) untuk klasifikasi fraud transaction detection.
- Mengevaluasi dan membandingkan kinerja model menggunakan metrik yang sesuai (presisi, recall, F1-score,)

Scope

- **Data**
  - Analisis dataset credit card fraud berisi feature/attribute waktu transaksi (trans_date_trans_time, unix_time), lokasi (lat, long, merch_lat, merch_long), nominal transaksi (amt), data identitas pengguna (gender, job, city_pop, dob)
- **Machine Learning Models**
  - Implementasi supervised learning algorithms: Logistic Regression, Random Forest, AdaBoost.
  - Analisa feature importance untuk memahami peran masing-masing variabel dalam mendeteksi transaksi fraud.

Dataset yang Digunakan	Credit Card Fraud
Dimensi Data	• 1296675 data • 21 Feature • 1 Label Category
Fitur	• trans_date_trans_time, cc_num • merchant, category • amt, first • last, gender • street, city • state, zip, lat • long, city_pop • job, dob • trans_num, unix_time • merch_lat, merch_long
Target Variabel	• Fraud / Tidak Fraud
Missing Values	• Tidak Ada
Duplicates	• Tidak Ada

EDA & Data Preparation

	Category	Value	Percentage
0	0	1289169	99,42114
1	1	7506	0,57887

Target distribution :

Class 0 (Not Fraud): 1289169

Class 1 (Fraud): 7506

Kesimpulan : **Class Imbalance**

EDA & Data Preparation

1. Membuat Feature Baru

- Untuk feature [trans_date_trans_time], dipecah dan menjadikan feature baru [tahun, bulan, hari,hour, day of week]. Ini dilakukan untuk mempermudah analaisa.
- Setelah itu berdasarkan feature [hour], melakukan perbandingan is_fraud = 1 untuk tiap jam. Di dapatkan ada 3 kategori utama untuk resiko waktu terjadi fraud. Risk time dan safe time

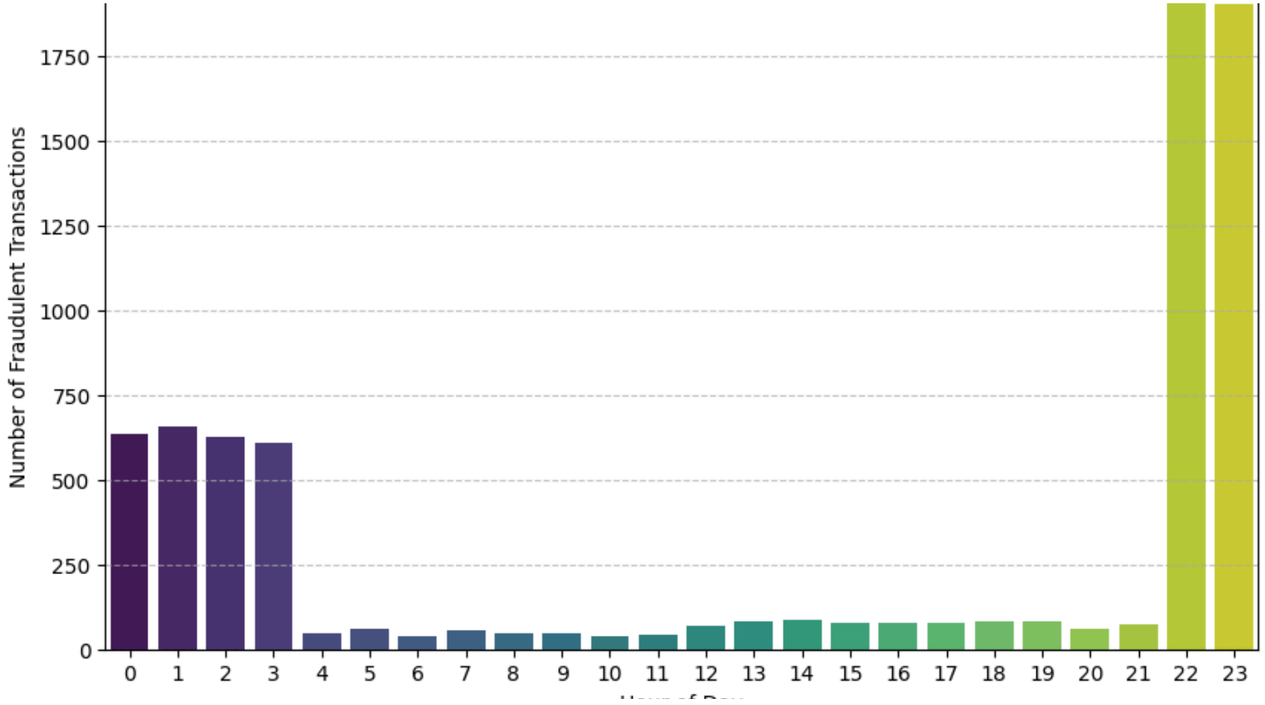

EDA & Data Preparation

2. Age / Umur

- Dari feature [dob], dijadikan feature baru [age]. Dengan cara feature [year] dikurang feature [dob]. Pengertian dari feature [age] adalah umur dari identitas saat melakukan transaksi
- Setelah itu melakukan perbandingan is_fraud = 1 untuk setiap feature [age]. Di temukan outlier saat melakukan transaksi di bawah umur 17 tahun sekitar 100 transaksi kemudian di drop.

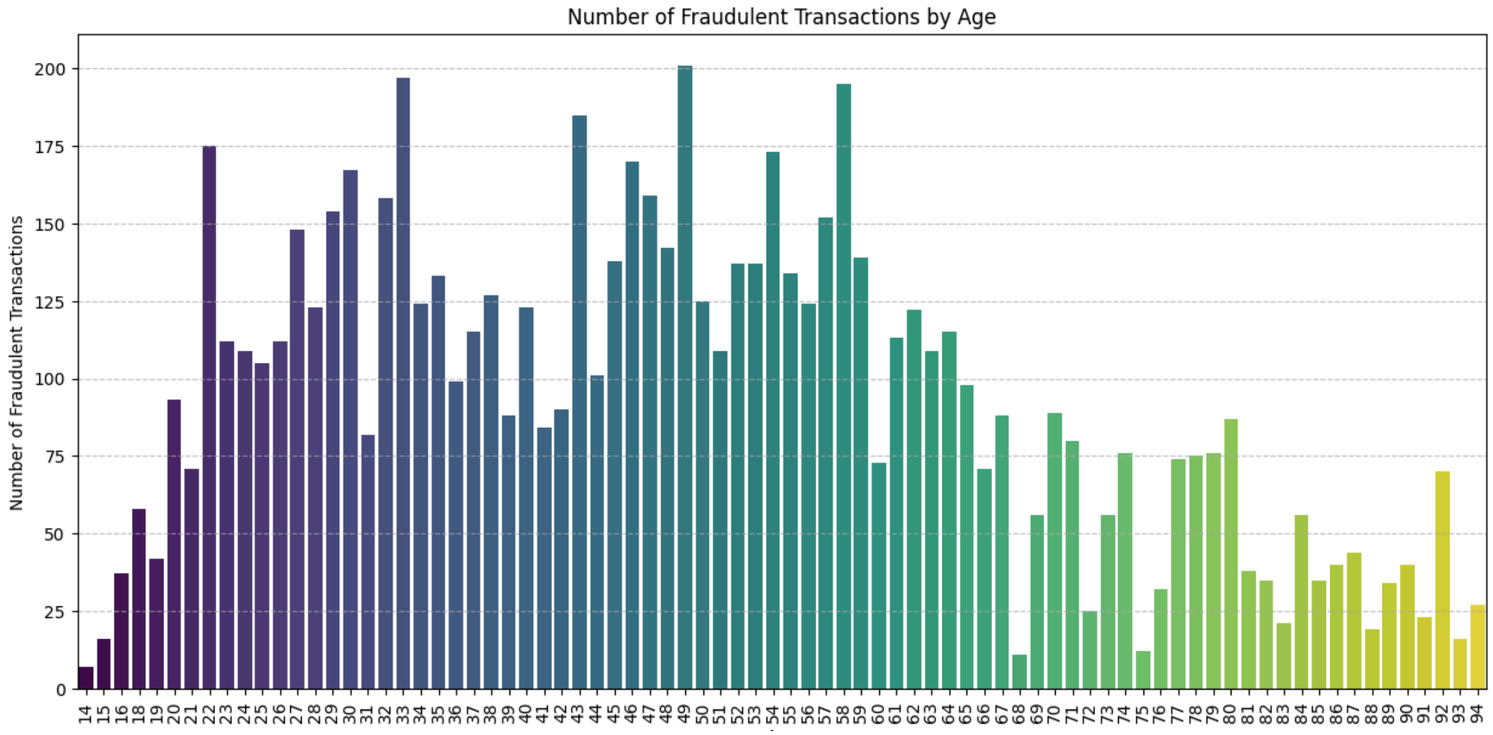

EDA & Data Preparation

3. Distance

- Dari feature lat1, lon1, lat2, lon2 diubah dengan rumus harvesine untuk mendapatkan distance dan dibuatkan feature baru [distance]

```
# Fungsi untuk menghitung jarak menggunakan rumus Haversine
def haversine(lat1, lon1, lat2, lon2):
    # Konversi dari derajat ke radian
    lat1, lon1, lat2, lon2 = map(np.radians, [lat1, lon1, lat2, lon2])

    # Haversine formula
    dlon = lon2 - lon1
    dlat = lat2 - lat1
    a = np.sin(dlat/2)**2 + np.cos(lat1) * np.cos(lat2) * np.sin(dlon/2)**2
    c = 2 * np.arcsin(np.sqrt(a))

    # Jarak dalam kilometer (radius bumi = 6371 km)
    distance = 6371 * c
    return distance
```

```
# Menghitung jarak untuk setiap transaksi
data['distance'] = data.apply(lambda row: haversine(row['lat'], row['long'], row['merch_lat'], row['merch_long']), axis=1)
```

EDA & Data Preparation

4. Label Encoding

- Untuk feature [category] dilakukan label encoding berdasarkan frequency.
- Untuk feature [city_pop] dilakukan label encoding berdasarkan jumlah populasi menjadi 3 kategori :

  low,medium dan high (1,2,3).

5. Drop Feature

- Untuk feature [gender] didrop karena seimbang antara pria dan wanita dalam jumlah fraud
- Untuk feature identifier ['cc_num', 'first', 'last', 'trans_num'] di drop karena berupa identitas
- Untuk feature categorical, jumlah nunique nya banyak di drop untuk mempermudah model dalam analisa

EDA & Data Preparation

Feature yang didapat :

1. Amt
2. Category_coding
3. Age
4. Hour
5. Day
6. Risk_category_of_hour
7. Month
8. Day_of_Week
9. City_pop_category
10. Distance_category

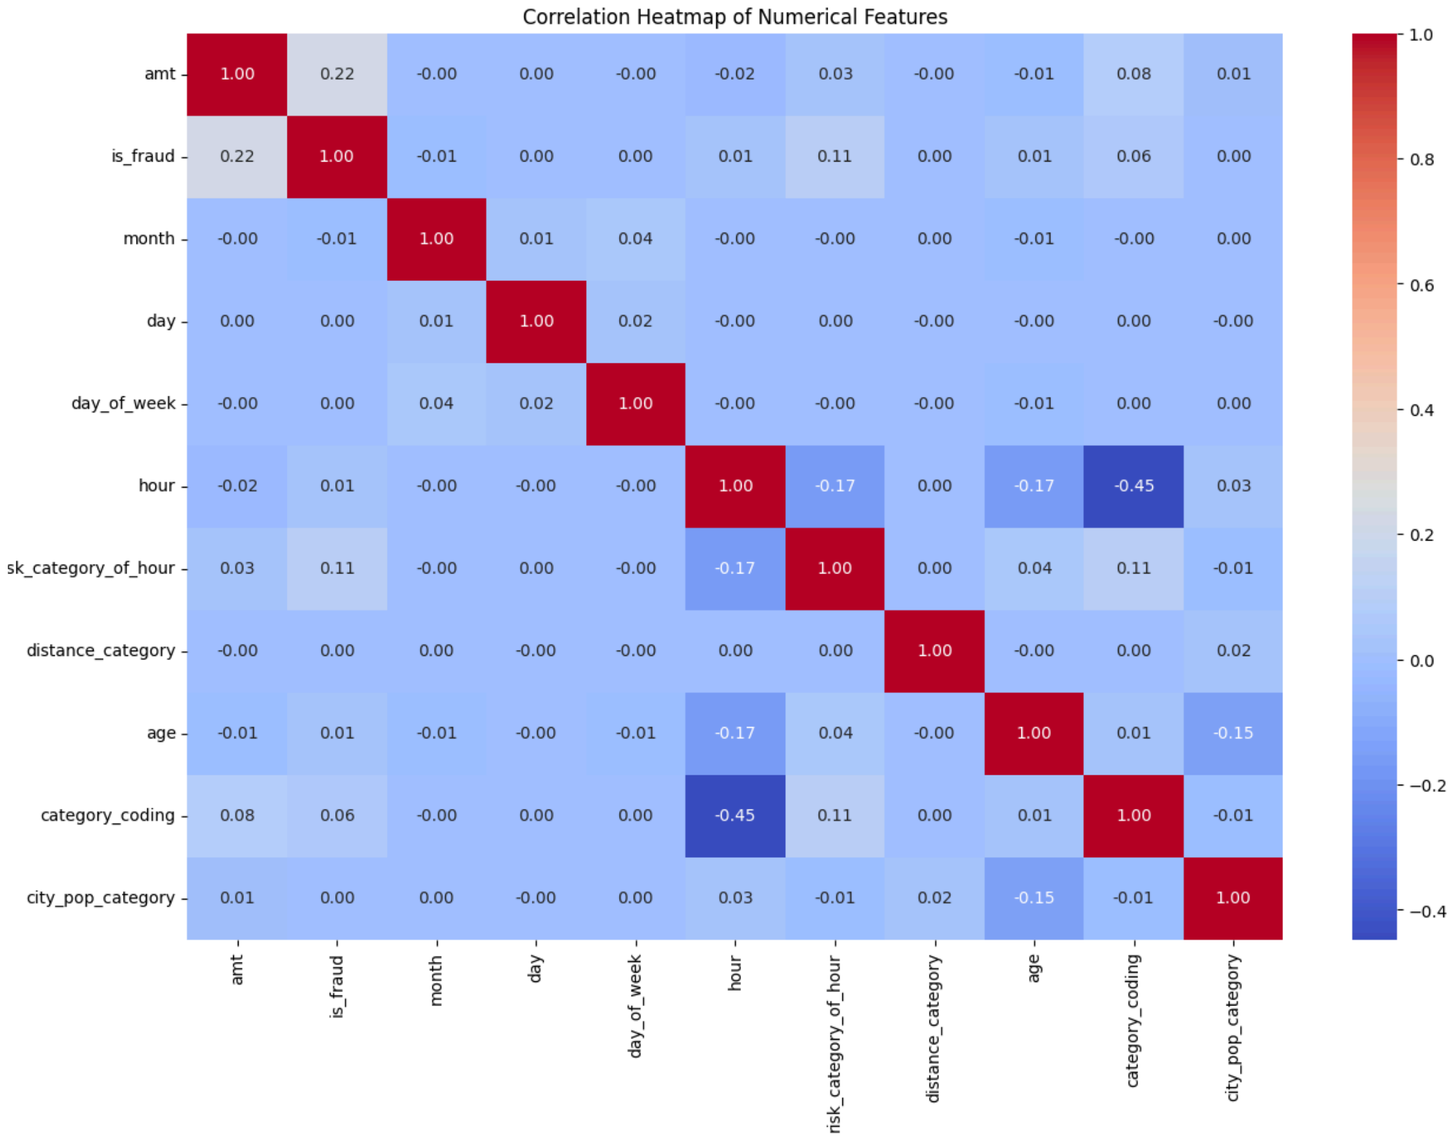

Model Development

- **Logistic Regression**
- **Random Forest**
- **Adaboost**

Model Evaluation

No	Model	Macro Avg F1-score	Accuracy
1	Logistic Regression	0,51356	0,99375
2	Random Forest	0,91790	0,99831
3	AdaBoost	0,73858	0,99547

Best model : Random Forest

- Avg F1-Score: 0.91790
- Accuracy : 0.99831

Analisa :

1. Perbedaan besar antara accuracy dan F1-score menunjukkan:
- Model bisa saja “terlihat bagus” tetapi sebenarnya tidak efektif dalam mendeteksi fraud.

2. Random Forest unggul karena:
- Mampu menangkap pola kompleks
- Lebih robust terhadap data tidak seimbang

3. Logistic Regression kurang optimal:
- Cenderung bias ke kelas mayoritas
- Perlu penanganan khusus

Model Evaluation

Random Forest

	Precison	Recall	F1-Score	Support
0	1	1	1	255160
1	0,95	0,75	0,84	1489
Accuracy			1	256649
Macro Avg	0,97	0,87	0,92	256649
Weig Avg	1	1	1	256649

Macro Average F1-score: 0.9179
Accuracy: 0.9983

Random Forest - Confusion Matrik

	Prediksi: Negatif (0)	Prediksi: Positif (1)
Aktual: Negatif (0)	255.100 (TN)	60 (FP)
Aktual: Positif (1)	375 (FN)	1.114 (TP)

- 255.100 Transaksi Normal yang memang diprediksi Normal.Operasional lancar, nasabah tidak terganggu.
- 1.114 Fraud yang berhasil Dideteksi.Keuntungan bagi perusahaan; kerugian berhasil dicegah.
- 60 Transaksi Normal tapi dianggap Fraud.False Alarm. Nasabah komplain karena kartu diblokir atau transaksi ditolak padahal sah.
- 375 Fraud tapi dianggap Normal.Kecolongan. Ini adalah lubang keamanan. Uang hilang.

Feature Importance

No	Feature	Importance	Percentage (%)
1	amt	471.862	47.186
2	category_coding	196.683	19.668
3	age	102.148	10.214
4	hour	76.949	7.694
5	day	39.102	3.910
6	risk_category_of_hour	36.912	3.691
7	month	26.286	2.628
8	day_of_week	22.300	2.229
9	city_pop_category	14.597	1.459
10	distance_category	13.161	1.316

Analisa :

- Feature paling Berpengaruh, amt (47.19%). Merupakan feature paling dominan dalam deteksi fraud.
- Feature Berpengaruh Tinggi, category_coding (19.67%), age (10.21%)
- Feature Berpengaruh Menengah
  - hour (7.69%) ➤ Waktu transaksi dalam sehari sangat relevan (fraud sering terjadi di jam tidak biasa).
  -day (3.91%)
  -risk_category_of_hour (3.69%) ➤ Kombinasi waktu dan tingkat risiko jam tertentu membantu meningkatkan deteksi.
- Feature Berpengaruh Rendah
  -month (2.63%)
  -day_of_week (2.23%)
  -city_pop_category (1.46%)
  -distance_category (1.32%)

Conclusion

- Dari EDA, terdapat jam yang beresiko terjadi transaksi fraud yaitu jam 22.00 s/d 03.00 pagi
- Dari model ML yang kami training model yang menjadi terbaik : **Random Forest**. Macro Avg F1- score : 0,9179
- Macro Avg F1-score mengukur seberapa baik model dalam menangani kedua kelas secara seimbang, sehingga sangat penting digunakan pada kasus fraud detection yang memiliki data tidak seimbang.
- 4 Top Feature importance : Amt, category_coding, age, hour. Tindakan pencegahan dapat dilakukan :

1. Amt : Terapkan limit dinamis dan verifikasi biometrik pada nilai tinggi.
2. Category : Perketat pengamanan pada merchant kategori barang mewah/aset digital.
3. Age : Proteksi khusus untuk transaksi yang tidak sesuai pola umur nasabah.
4. Hour : Tingkatkan kewaspadaan sistem dan ketersediaan tim investigasi pada jam malam.

Real-World Application

Perbankan & Kartu Kredit

Sistem AI digunakan oleh bank untuk memantau setiap transaksi kartu kredit secara real-time. Ketika ada transaksi yang mencurigakan (misalnya lokasi tiba-tiba jauh atau nominal tidak biasa), sistem akan:

- Menolak transaksi secara otomatis
- Mengirim notifikasi ke pengguna
- Meminta verifikasi tambahan

Feature Improvement

- Untuk keperluan dataset bisa menggunakan dataset yang ada
- Potensi untuk meningkatkan performa model dengan menambah feature improvement

AI UNTUK SEMUA

Thank you